

PROJECT HELIOS

Globales Renewable-First-Rechenzentrumsnetzwerk
für das Training grosser Sprachmodelle (LLMs)

Konzeptstudie: Standortwahl, politische Stabilität, Energieversorgung,
Checkpointing-Architektur, Verfügbarkeit und Kostenmodell

Erstellt am 18.07.2026

Auftraggeber / Copyright: Frank Arendt

Erstellt mit Claude (Anthropic) — Recherche- & Modellierungsstudie

Vertraulich — Konzeptpapier, keine Investitionsempfehlung

1. Einführung

Das Training und der Betrieb grosser Sprachmodelle (Large Language Models, LLMs) sind zu einem signifikanten Faktor der globalen Stromnachfrage geworden. Diese Studie entwirft ein Konzept für ein global verteiltes Rechenzentrumsnetzwerk, das für das Training grosser LLMs ausgelegt ist und dessen Standorte so gewählt sind, dass ein maximal hoher Anteil erneuerbarer Energien (Photovoltaik und, wo möglich, Windkraft) direkt vor Ort genutzt werden kann. Russland und China sind aus geopolitischen Gründen und wegen exportkontrollrechtlicher Erwägungen bei vergleichbaren realen Projekten explizit als Standorte ausgeschlossen.

1.1 Zwei Nutzungsphasen von KI: Training und Inferenz

Der Lebenszyklus eines LLMs gliedert sich in zwei energetisch sehr unterschiedliche Phasen. In der **Trainingsphase** wird ein Modell einmalig (bzw. bei Weiterentwicklungen in wiederkehrenden, aber diskreten Zyklen) auf sehr grossen Datenmengen trainiert. Dies erfordert über Wochen bis Monate hinweg tausende bis zehntausende Beschleuniger (GPUs/TPUs) im Dauerbetrieb bei nahezu konstanter Volllast – ein klar abgrenzbares, planbares Lastprofil. In der **Nutzungs- bzw. Inferenzphase** wird das fertige Modell danach fortlaufend – teils über Jahre – für Milliarden von Anfragen eingesetzt. Dieses Lastprofil ist volatil, folgt Nutzerverhalten und Tageszeiten und läuft praktisch rund um die Uhr.

Der Anteil beider Phasen am Gesamtstromverbrauch eines Modells über seinen Lebenszyklus wird in der Fachliteratur unterschiedlich beziffert, mit einem klaren Trend: Während frühe Analysen (u. a. von Google für den Zeitraum 2019–2021) einen Inferenzanteil von rund 60 % gegenüber 40 % Training ermittelten, gehen neuere Untersuchungen aus 2025/2026 angesichts der massenhaften Verbreitung von KI-Assistenten von einem deutlich höheren Inferenzanteil von 80–90 % aus, während auf die Trainingsphase nur noch 10–20 % entfallen. Eine Studie beziffert die jährlichen Rechenkosten der Inferenz auf etwa das 25-fache der einmaligen Trainingskosten eines Modells. Für die vorliegende Studie wird daher die Bandbreite **Training $\approx$ 15–30 %, Inferenz $\approx$ 70–85 %** des Lebenszyklus-Stromverbrauchs zugrunde gelegt, mit der Tendenz, dass sich der Inferenzanteil mit wachsender Nutzerbasis weiter erhöht.

*Anmerkung: Das hier konzipierte Rechenzentrumsnetzwerk ist ausschliesslich auf die **Trainingsphase** ausgelegt (planbare, verlagerbare Volllast). Die Inferenzphase wird aus guten Gründen üblicherweise näher am Endnutzer und redundant in vielen kleineren, netznahen Rechenzentren betrieben, da sie latenzkritisch ist und sich schlechter über wenige, weit entfernte Standorte verlagern lässt.*

1.2 Anteil von KI-Rechenzentren am globalen Stromverbrauch

Nach Angaben der Internationalen Energieagentur (IEA) verbrauchten Rechenzentren weltweit 2024 rund 415 TWh Strom; für 2025 wird ein Anstieg auf etwa 485 TWh angenommen. Bis 2030 soll sich dieser Wert auf rund 945–950 TWh nahezu verdoppeln, was etwa 3 % des dann prognostizierten globalen Stromverbrauchs entspricht (2024 lag der Anteil noch bei rund 1,5 %). Bis 2035 wird in der Basisprognose der IEA ein weiterer Anstieg auf rund 1.200 TWh erwartet. Besonders dynamisch wächst dabei das KI-Segment: Der Stromverbrauch KI-fokussierter Rechenzentren soll sich zwischen 2025 und 2030 nahezu verdreifachen und damit deutlich schneller wachsen als der Rechenzentrumssektor insgesamt. Die USA und China vereinen zusammen fast 80 % des globalen Nachfragezuwachses bis 2030 auf sich; Europa trägt mit einem geschätzten Zuwachs von rund 45 TWh (+70 %) einen kleineren, aber ebenfalls wachsenden Anteil bei.

Globaler Stromverbrauch von Rechenzentren: historisch & Prognose (Basis: IEA 2025/20)




Abb. 1: Historischer und prognostizierter globaler Stromverbrauch von Rechenzentren sowie geschätzter Anteil KI-fokussierter Rechenzentren, 2020–2035. Werte 2020–2025 nach IEA-Angaben (Energy and AI, 2025; Key Questions on Energy and AI, 2026); Werte ab 2026 sind lineare Interpolationen zwischen publizierten IEA-Stützpunkten (2030: 945 TWh, 2035: 1.200 TWh). Der KI-Anteil ab 2026 ist eine eigene, literaturgestützte Schätzung (Tripling KI-Anteil 2025–2030 gemäss IEA) und keine offizielle IEA-Einzelprognose.

2. Projektkonzept: Follow-the-Renewables-Architektur

Das Konzept folgt dem Prinzip verteilten, energie-bewussten Trainings ('carbon-/renewable-aware distributed training'), wie es in aktueller Forschung zu geo-verteiltem LLM-Training beschrieben wird (u. a. GeoPipe, 2025; Green Distributed AI Training, 2025; Distributed LLM Pretraining During Renewable Curtailment Windows, 2026). Anstatt ein einzelnes Grossrechenzentrum permanent aus dem lokalen Netz zu versorgen, wird die Trainingslast zwischen mehreren, über die Erde verteilten Standorten verlagert – jeweils dorthin, wo gerade ausreichend PV- und/oder Windstrom lokal verfügbar ist. Der Modellzustand wird dazu per Checkpointing periodisch gesichert und bei Bedarf auf einen anderen Standort übertragen.

2.1 Eckdaten pro Standort

Parameter	Wert	Kommentar
IT-Leistung je Rechenzentrum	2 GW	Vorgabe des Auftraggebers
Batteriekapazität je Standort	12 GWh	≈ 6 Std. Autonomie bei 2 GW Volllast
Anzahl Standorte	6	je 2 in Cluster 'Amerika' und 'EMEA-West', 2 Anker-Standorte
Gesamt-IT-Leistung Flotte	12 GW	6 × 2 GW
Gesamt-Batteriekapazität	72 GWh	6 × 12 GWh
Energieerzeugung	PV + Wind (Hybrid)	je Standort, Mischungsverhältnis standortabhängig

Tab. 1: Technische Eckdaten des Konzepts (Vorgaben und abgeleitete Grössen).

2.2 Optimierung der Standortwahl zur Minimierung von Verlagerungsoperationen

Eine naive 'Follow-the-Sun'-Architektur mit gleichmässig über alle Längengrade verteilten Standorten würde eine Verlagerung etwa alle 3–4 Stunden erzwingen, da jeder Standort nur ein enges Zeitfenster mit ausreichend Solarstrahlung hätte. Um die Zahl der Verlagerungsoperationen zu minimieren, werden im vorliegenden Konzept die Standorte stattdessen in zwei geografisch benachbarte **Cluster** gruppiert sowie durch zwei alleinstehende **Anker-Standorte** mit besonders konstanter Windversorgung ergänzt:

- **Cluster EMEA-West** (Spanien & Marokko, gleiche/benachbarte Zeitzone, ~1.650 km Distanz): PV-Erzeugungsspitzen liegen zeitlich fast deckungsgleich, sodass innerhalb des Clusters primär kurze, günstige Verlagerungen über eine private Glasfaserstrecke erfolgen und selten in ein anderes Cluster ausweichen muss.
- **Cluster Amerika** (Chile & USA-Texas, ~8.200 km Distanz, 2 Zeitzonen Versatz): die Zeitverschiebung verlängert das gemeinsame Tagesfenster der beiden Standorte spürbar, wodurch weniger externe Verlagerungen nötig sind.
- **Anker Norwegen** und **Anker Australien**: beide verfügen über sehr konstante, wenig saisonal schwankende Windressourcen und dienen als seltene, clusterübergreifende Ausweichstandorte für den Fall, dass ein gesamtes Cluster gleichzeitig in ein Erzeugungstief fällt (z. B. grossflächige Wetterlage).

Durch die 6-Std.-Batteriepufferung je Standort (12 GWh / 2 GW) werden zusätzlich kurze Erzeugungslücken lokal abgefangen, ohne dass überhaupt eine Verlagerung nötig wird. Dieses Zusammenspiel aus Cluster-Bildung, Batteriepufferung und Hybrid-Erzeugung (PV + Wind) reduziert die Zahl der Verlagerungsoperationen gegenüber einer gleichmässig verteilten 6-Standorte-Architektur um einen geschätzten Faktor von 2–3 (siehe Abschnitt 5.3).

2.3 Checkpointing-Mechanik

Beim Checkpointing wird der vollständige Trainingszustand – Modellgewichte sowie (optional, komprimiert) Optimierer-Zustände wie Adam-Momente – periodisch auf einen persistenten Speicher geschrieben. Für ein angenommenes Modell im Grössenbereich heutiger Frontier-Systeme (Grössenordnung $\sim 1\text{--}2$ Billionen Parameter) ergibt sich bei bf16-Präzision ein reiner Gewichts-Checkpoint von grössenordnungsmässig 2–4 TB; unter Einbeziehung eines minimalen, komprimierten Optimierer-Anteils (vgl. Kompressionsverfahren wie ExCP oder GoCkpt, die Checkpoint-Grössen um 70–90 % reduzieren können) wird für die Verlagerung zwischen Standorten eine Übertragungsgrösse von rund **2 TB je Ereignis** angenommen. Über eine dedizierte Glasfaserstrecke mit 400 Gbit/s nutzbarer Kapazität ergibt sich daraus eine reine Übertragungszeit von rund 40–80 Sekunden – deutlich innerhalb der aus der Literatur bekannten Zeitfenster für praktikable Migrationen (vgl. Green Distributed AI Training, 2025: Machbarkeitsschwellen von 60–300 Sekunden je nach Checkpoint-Grösse und Bandbreite). Während der Übertragung wird das Training am Zielstandort aus dem letzten Checkpoint fortgesetzt ('elastic switching' zwischen Einzelstandort- und föderiertem Multi-Standort-Betrieb).

3. Standortauswahl

Die folgenden sechs Standorte wurden nach den Kriterien (a) hohes PV- und/oder Windpotenzial, (b) Netzanschluss-/Flächenverfügbarkeit, (c) Zeitzonenlage zur Cluster-Optimierung und (d) politische Stabilität ausgewählt. Russland und China wurden vorgabegemäss ausgeschlossen.

Standort	Koordinaten	Zeitzone	Cluster	PV	Wind	Rolle
Norwegen – Nordland (Narvik)	68,4° N / 17,4° O	UTC+1	Anker Nord	gering (Polarnacht)	sehr hoch (Fjord-/Küstenwind)	Anker / Backup
Spanien – Extremadura	39,2° N / 6,3° W	UTC+1	EMEA-West	sehr hoch	hoch	Cluster-Partner
Marokko – Dakhla (Westsahara-Küste)	23,7° N / 15,9° W	UTC+0	EMEA-West	extrem hoch	sehr hoch (Passatwind)	Cluster-Partner
Chile – Atacama (Region Antofagasta)	23,7° S / 69,6° W	UTC-4	Amerika	weltweit höchste Werte	moderat (Küste)	Cluster-Partner
USA – West-Texas (Permian Basin)	32,0° N / 102,1° W	UTC-6	Amerika	hoch	sehr hoch (Windkorridor)	Cluster-Partner
Australien – South Australia (Port Augusta)	32,5° S / 137,8° O	UTC+9,5	Anker Süd	sehr hoch	sehr hoch	Anker / Backup

Tab. 2: Übersicht der sechs ausgewählten Standorte.

3.1 Erforderliche Grundstücksflächen

Für PV, Wind und den Rechenzentrums-Campus selbst ergeben sich je nach Standort sehr unterschiedliche Flächenbedarfe. PV-Flächen skalieren mit der installierten Nameplate-Leistung (≈ 3 ha/MW); Windparks benötigen als **Bruttoprojektfläche** (inkl. Turbinenabstand) deutlich mehr Fläche (≈ 35 ha/MW), wovon jedoch nur ein kleiner Teil tatsächlich versiegelt wird und der Rest meist weiter landwirtschaftlich nutzbar bleibt (siehe Abschnitt 7.1a zur Kostenbehandlung). Für den Rechenzentrums-Campus selbst (Gebäude, Kühlung, Umspannwerk, Personal- und Sicherheitsinfrastruktur) wird pauschal 1,5 km² je Standort angesetzt.

Standort	PV-Fläche	Wind-Bruttofläche	RZ-Campus	Gesamtfläche (Bruttofussabdruck)
Norwegen	≈ 26 km ²	≈ 1.700 km ²	$\approx 1,5$ km ²	≈ 1.728 km ²
Spanien	≈ 156 km ²	≈ 978 km ²	$\approx 1,5$ km ²	≈ 1.136 km ²
Marokko	≈ 89 km ²	≈ 1.038 km ²	$\approx 1,5$ km ²	≈ 1.129 km ²
Chile	≈ 158 km ²	≈ 614 km ²	$\approx 1,5$ km ²	≈ 774 km ²
USA-Texas	≈ 63 km ²	≈ 1.097 km ²	$\approx 1,5$ km ²	≈ 1.161 km ²
Australien	≈ 100 km ²	≈ 1.171 km ²	$\approx 1,5$ km ²	≈ 1.273 km ²

Tab. 2a: Flächenbedarf je Standort (NREL-Benchmark: PV ≈ 3 ha/MW, Onshore-Wind ≈ 35 ha/MW Bruttoprojektfläche). Die Wind-Bruttofläche wird überwiegend gepachtet statt gekauft (nur 1–3 % effektiv versiegelt); die zugehörigen Grundstückskosten sind in Abschnitt 7.1a hergeleitet.




Abb. 2: Schematische globale Verteilung der sechs Rechenzentrumsstandorte. Die Karte zeigt eine grob orientierende, nicht kartografisch exakte Darstellung von Kontinent-Zonen sowie die geplanten privaten Glasfaserverbindungen innerhalb der beiden Cluster.

4. Bewertung der politischen Stabilität

Zur Einschätzung der politischen Stabilität wird auf den Global Peace Index (GPI) 2025 des Institute for Economics & Peace zurückgegriffen, der 163 Länder anhand von gesellschaftlicher Sicherheit, innerstaatlichen/internationalen Konflikten und Militarisierung bewertet. Bemerkenswert ist, dass die USA im GPI 2025 nur Rang 128 von 163 belegen – hinter Ländern wie Südafrika und Kenia –, was auf innenpolitische Faktoren wie hohe Waffengewalt und Polarisierung zurückgeführt wird. West- und Mitteleuropa gelten laut GPI weiterhin als die friedlichste Weltregion.

Standort	Einschätzung	GPI-Kontext 2025	Sicherheitsstatus
Norwegen	sehr hoch	Nordische Staaten zählen zu den friedlichsten Ländern weltweit (Top ~20)	Standard-Objektschutz
Spanien	hoch	Teil der weltweit friedlichsten Region (West-/Mitteleuropa)	Standard-Objektschutz
Marokko (Westsahara-Region)	moderat, mit lokalem Risiko	Grundsätzlich stabile Monarchie, jedoch ungelöster Territorialkonflikt um die Westsahara in unmittelbarer Standortnähe	Erhöht – bewaffnete Schutztruppe (s. Abschnitt 7.3)
Chile	gut, verbessernd	Südamerika war 2025 die einzige Region mit GPI-Verbesserung; Chile zählt regional zu den stabileren Staaten	Standard-Objektschutz
USA (Texas)	moderat	GPI-Rang 128/163 (innenpolitisch bedingt); regional/institutionell dennoch verlässlicher Rechtsrahmen	Erweiterter ziviler Objektschutz
Australien	sehr hoch	Regelmässig unter den friedlichsten und stabilsten Staaten des indopazifischen Raums	Standard-Objektschutz

Tab. 3: Politische Stabilitätsbewertung je Standort auf Basis des Global Peace Index 2025.

Nur der Standort Marokko/Dakhla wird aufgrund des ungelösten Territorialkonflikts um die Westsahara als Standort mit erhöhtem Sicherheitsrisiko eingestuft und erhält dementsprechend das in Abschnitt 7.3 beschriebene Sicherheitspaket. Der texanische Standort erhält einen erweiterten zivilen Objektschutz, jedoch keine militärisch ausgerüstete Schutztruppe, da es sich um gesellschaftlich-institutionelle statt um territoriale Konfliktrisiken handelt.

5. Auslastung, Verlagerungsoperationen und Verfügbarkeit

Da für ein derartiges globales KI-Trainingsnetzwerk keine öffentlich zugänglichen historischen Betriebsdaten existieren, wird in diesem Abschnitt ein Modell verwendet, das auf publizierten Solar-/Windprofilen der jeweiligen Regionen sowie auf Kennzahlen aus aktueller Forschung zu energie-bewusstem, geo-verteiltem KI-Training kalibriert ist (u. a. mittlere Erneuerbaren-Überschussfenster von rund 2,5 Std. gemäss CAISO-Kurvenanalyse in 'Green Distributed AI Training', 2025). Die nachfolgenden Werte sind somit **modellierte Schätzungen**, keine gemessenen historischen Zeitreihen eines real existierenden Systems.

5.1 24-Stunden-Überlagerung der Standorte




Abb. 3: Oben: modellierter, standort-normierter Erzeugungsindex (PV+Wind) der sechs Standorte über 24 Stunden (UTC). Unten: resultierende Deckung der Gesamtflotte in Prozent des Tagesmaximums; die gestrichelte Linie markiert die Schwelle, ab der die 6-Std.-Batteriepufferung nicht mehr ausreicht und eine Verlagerung ausgelöst wird.

5.2 Jahresverlauf und Nord-/Südhalbkugel-Komplementarität

Da drei Standorte auf der Nord- (Norwegen, Spanien, Marokko, USA) und zwei auf der Südhalbkugel (Chile, Australien) liegen, gleichen sich saisonale Schwankungen der PV-Erzeugung auf Flottenebene teilweise aus: Während in den nordhemisphärischen Wintermonaten die Erzeugung dort sinkt, steigt sie in Chile und Australien (Südhemisphären-Sommer) an. Dieser Effekt glättet den Jahresverlauf der Gesamtflotte spürbar gegenüber einer rein nordhemisphärischen Standortwahl.




Abb. 4: Modellierter Jahresverlauf des Erneuerbaren-Deckungsgrads je Standort sowie Flottenmittel. Die Kurven basieren auf typischen saisonalen PV-/Wind-Profilen der jeweiligen Breitengrade und sind eine schematische Näherung, keine Messreihe.

5.3 Verlagerungsoperationen

Unter den in Abschnitt 2.2 beschriebenen Cluster- und Pufferannahmen ergibt das Modell folgende durchschnittliche Häufigkeit von Checkpoint-Verlagerungen:




Abb. 5: Modellierter Verlagerungsoperationen pro Tag und Jahr, aufgeschlüsselt nach Cluster-intern (häufig, kurze Distanz, private Glasfaser) und cluster-übergreifend (selten, lange Distanz, öffentliche/gemietete Backbone-Kapazität).

Kategorie	Ø Operationen/Tag	Operationen/Jahr	Übertragungsweg
Spanien ↔ Marokko	2,0	≈ 730	private Glasfaser (~1.650 km)
Chile ↔ USA-Texas	2,0	≈ 730	private Glasfaser (~8.200 km, inkl. Seekabelanteil)
Cluster-übergreifend (inkl. Anker)	0,5	≈ 180	gemietete Backbone-/Wellenlängenkapazität
Gesamtsystem	≈ 4,5	≈ 1.640	—

Tab. 4: Modellierte Verlagerungsoperationen (eigene Schätzung, kalibriert an publizierten Erneuerbaren-Überschussfenstern, keine historische Messreihe).

5.4 Nutzungsrate je Standort und Systemverfügbarkeit

Standort	Lokale Erneuerbaren-Deckung	Nutzungsrate (Auslastung)	Bemerkung
Norwegen	≈ 92 %	≈ 90 %	ganzjährig konstanter Wind
Spanien	≈ 88 %	≈ 85 %	starke PV-Saisonalität
Marokko	≈ 95 %	≈ 92 %	PV + Passatwind ganzjährig hoch
Chile	≈ 90 %	≈ 88 %	höchste PV-Einstrahlung weltweit
USA-Texas	≈ 85 %	≈ 83 %	starker, aber variabler Windkorridor
Australien	≈ 93 %	≈ 91 %	PV + Wind sehr hoch, geringe Saisonalität

Tab. 5: Modellierte lokale Erneuerbaren-Deckung und resultierende Nutzungsrate (Anteil der Zeit, in der ein Training-Job ohne Verlagerung am jeweiligen Standort weiterlaufen kann).

Die **Systemverfügbarkeit** ergibt sich aus der Kombination von Batteriepufferung, Hybrid-Erzeugung und der Möglichkeit, bei lokalem Engpass auf einen Cluster-Partner oder Anker-Standort auszuweichen. Für ein System aus 6 weitgehend unabhängigen Standorten (unterschiedliche Wetterlagen, Netze und Zeitzonen) mit je 6 Std. Batterie-Autonomie ergibt eine vereinfachte Verfügbarkeitsrechnung nach dem Prinzip 'mindestens ein Standort verfügbar' eine geschätzte **Gesamtverfügbarkeit des Trainingsjobs von rund 99,95–99,99 %** im Jahresmittel (entspricht einer nicht-verfügbaren Zeit von rund 4–26 Stunden pro Jahr, primär durch geplante Wartung und seltene, gleichzeitige Wetterereignisse in mehreren Clustern gleichzeitig).

6. Wetterprognose und Planungshorizont für Verlagerungsoperationen

Für die in Kapitel 5 beschriebene Steuerung der Verlagerungsoperationen stellt sich die Frage, wie weit im Voraus solche Operationen verlässlich geplant werden können. Dieses Kapitel untersucht, ob und in welchem Umfang ein Vorlauf von **48 Stunden** ausreichend stabile Wettervorhersagen liefert, um Checkpoint-Verlagerungen planbar auszulösen – und wo dies durch Extremwetterereignisse an Grenzen stösst.

6.1 Prognosegüte in Abhängigkeit vom Vorhersagehorizont

Numerische Wettervorhersagen (NWP) verlieren mit zunehmendem Vorhersagehorizont systematisch an Genauigkeit, da sich kleine Anfangsunsicherheiten der Atmosphäre chaotisch verstärken. Für PV- und Windleistungsprognosen zeigt eine Studie zu erneuerbaren-betriebenen modularen Rechenzentren exemplarisch, dass der mittlere absolute prozentuale Fehler (MAPE) von rund 8,5–9 % bei 3-Stunden-Vorhersagen auf 18–25 % bei Day-ahead-Vorhersagen (24 h) und weiter auf 44–75 % bei Wochenvorhersagen ansteigt. Für den in diesem Projekt relevanten 48-Stunden-Horizont ist demnach ein Prognosefehler zwischen den Day-ahead- und Wochenwerten zu erwarten – in der Grössenordnung von grob 25–35 % MAPE unter Normalbedingungen, mit spürbar höheren Fehlern bei Extremwetterlagen (siehe 6.2). Führende globale Wettermodelle (ECMWF/HRES sowie neuere KI-basierte Modelle wie GraphCast oder Pangu-Weather) erreichen im 48-Stunden-Bereich generell noch eine hohe grundsätzliche Vorhersagegüte für Frontensysteme und Sturmtiefs, während die Intensität von Extremereignissen (Böenspitzen, Staubkonzentration, Vereisung) auch bei diesen Modellen deutlich unsicherer bleibt als die reine Eintrittswahrscheinlichkeit.




Abb. 7: Schematischer Verlauf des Prognosefehlers (MAPE) für PV- und Windleistung nach Vorhersagehorizont, kalibriert an publizierten Werten für 3h-, Day-ahead- und Wochenvorhersagen (*Exploring the Efficiency of Renewable Energy-based Modular Data Centers at Scale*, arXiv 2406.02252). Die gestrichelten oberen Linien zeigen den zusätzlichen Fehleraufschlag bei Extremwetterlagen (eigene Schätzung, siehe 6.2). Die 48h-Marke ist der für dieses Projekt relevante Planungshorizont.

6.2 Standortspezifische Extremwetterrisiken

Extremwetterereignisse verschlechtern die Prognosequalität in doppelter Hinsicht: Sie treten seltener und untypischer auf als das Normalwetter, wodurch Vorhersagemodelle schlechter kalibriert sind, und ihre Intensität (nicht nur ihr Eintreten) ist deutlich schwerer zu quantifizieren. Die folgende Übersicht ordnet jedem Standort sein dominantes Extremwetterisiko sowie eine Einschätzung der 48h-Prognosegüte unter Normal- und Extrembedingungen zu.

Standort	Dominantes Extremwetterisiko	Typische Vorwarnzeit	48h-Prognosegüte (normal / extrem)	Empfehlung für Planungsprozess
Norwegen	Sturmtiefs, Polarwirbel-Einbrüche, Vereisung von Windturbinen	2–4 Tage (gut erfassbare Frontensysteme)	Wind: hoch / mittel (Böenintensität unsicher)	48h-Vorwarnung nutzen für Batterie-Vollladung + Pre-Staging beim Anker-Partner
Spanien	Hitzewellen, Saharastaub-Intrusion ('Calima')	2–5 Tage (Hitzewelle) / 1–3 Tage (Calima)	PV: hoch / mittel-niedrig (Staubkonzentration unsicher)	48h ausreichend für Grobplanung; Feinabstimmung 12–24h vorher
Marokko (Dakhla)	Sandstürme (Chergui-Wind), Passatwind-Variabilität	1–3 Tage (Sandsturm oft kurzfristiger)	PV: mittel / niedrig; Wind: hoch / mittel	Erhöhte Sicherheitsmarge (zusätzliche Batteriereserve) wegen kürzerer Vorwarnzeit
Chile (Atacama)	Küstennebel ('Camanchaca', nur küstennah); ansonsten sehr stabile, trockenste Wetterlage weltweit	3–7 Tage (grossräumig stabil)	PV: sehr hoch / hoch	48h-Prognose sehr verlässlich; Standort eignet sich als Referenz-/Ausweichpunkt
USA-Texas	Schwere Gewitter, Tornados, winterliche Extremkälte mit Vereisung (Vorbild: Wintersturm Uri 2021)	3–5 Tage (Wintersturm) / Stunden (Gewitter/Tornado)	Wind: mittel / niedrig (Vereisungsrisiko schwer quantifizierbar)	Bei Wintersturm-Vorwarnung bereits bei 48h präventive Vollverlagerung nach Chile einleiten
Australien	Hitzewellen, Buschfeuerrauch (Aerosol-Verschattung von PV), vereinzelt Zyklonausläufer im Norden	3–7 Tage (Hitzewelle) / 1–2 Tage (Rauch, stark lageabhängig)	PV: hoch / mittel (Rauchdichte unsicher)	48h nutzen für Kapazitätsreservierung; Rauchereignisse zusätzlich per Satellitenmonitoring engmaschig verfolgen

Tab. 8: Standortspezifische Extremwetterrisiken und deren Einfluss auf die 48h-Prognosegüte (eigene Einschätzung auf Basis allgemeiner klimatologischer Kenntnisse der jeweiligen Region sowie publizierter Kennzahlen zur Prognosegüte; keine standortspezifische Einzelstudie).

6.3 Ableitung: Ein zweistufiger 48h-Planungsprozess

In der Gesamtschau ergibt sich, dass ein 48-Stunden-Vorlauf für die **grobe Kapazitätsplanung** gut geeignet ist, für die **automatisierte, harte Auslöseentscheidung** einer Verlagerung bei Extremwetter jedoch nicht allein ausreicht. Das Konzept sieht daher einen zweistufigen Prozess vor:

- **Stufe 1 – Vorwarnung (T-48h):** Auf Basis der 48h-Prognose wird bei erkennbarem Risiko eines Erneuerbaren-Einbruchs (z. B. Wintersturm-Vorhersage für Texas, Calima-Vorhersage für Spanien) der jeweilige Cluster-Partner in Bereitschaft versetzt: Reservierung von Rechenkapazität, Vorab-Replikation des letzten Checkpoints über die private Glasfaserverbindung und Vollladung der lokalen Batteriespeicher. Dieser Schritt verursacht keine Unterbrechung des laufenden Trainings.

- **Stufe 2 – Auslösung (T-6h bis T-0):** Die tatsächliche Verlagerung wird erst auf Basis von Echtzeit-Telemetriedaten (aktueller Batterieladestand, aktuelle PV-/Winderzeugung, kurzfristige Nowcasting-Daten) ausgelöst, da – wie in 6.1/6.2 gezeigt – die Prognosefehler bei 48h insbesondere für die Intensität von Extremereignissen zu hoch sind, um eine vollautomatische Hard-Trigger-Entscheidung allein auf Prognosebasis zu rechtfertigen. Die 6-Stunden-Batterieautonomie (Abschnitt 2.1) dient dabei als Puffer, um Fehlprognosen ohne Trainingsunterbrechung abzufangen.

Dieser zweistufige Ansatz nutzt die 48h-Vorhersage dort, wo sie zuverlässig ist (grossräumige Wetterlagen, Frontensysteme, mehrtägige Hitze-/Kältewellen), vermeidet aber eine Überinterpretation der Prognosegenauigkeit bei kurzfristigen, lokal begrenzten Extremereignissen wie Sandstürmen oder Gewitterzellen, bei denen Prognosefehler von 30 % und mehr auch bei 48h Vorlauf realistisch sind.

7. Kostenmodell

7.1 Stromkosten des Gesamtsystems (validiertes Eigenbetriebs-LCOE)

Alle Geldbeträge in diesem Dokument sind in US-Dollar (US\$) angegeben. Zugrunde gelegter Wechselkurs: 1 EUR = 1,08 US\$ (Annahme, Stand Sommer 2026); Beträge, die ursprünglich aus Euro-Marktdaten abgeleitet wurden, sind entsprechend umgerechnet.

Bei 12 GW installierter IT-Leistung und einer modellierten mittleren Auslastung von rund 88 % (gewichtetes Mittel aus Tab. 5) ergibt sich ein geschätzter Jahresstromverbrauch der Flotte von rund **12 GW × 8.760 h × 0,88 ≈ 92,5 TWh/Jahr** – zum Vergleich: mehr als der jährliche Stromverbrauch der Schweiz. Die Standortpreise werden hier – anders als in einer ersten, vereinfachten PPA-Annahme – als **Levelized Cost of Electricity (LCOE) bei Eigeninvestition** berechnet: Für jeden Standort wird aus dem standortspezifischen PV-/Wind-Mix (Tab. 2), realistischen technologiespezifischen Kapazitätsfaktoren, der zur Deckung von 2 GW netto-IT-Last nötigen Nameplate-Überbauung (inkl. rund 15 % Verlust durch Kurvenüberschuss/Batterie-Wirkungsgrad/Abregelung), den CAPEX-Sätzen aus Abschnitt 8.1 **sowie den Grundstückskosten aus Abschnitt 7.1a** die jährliche Kapitalwiedergewinnung zuzüglich 2 % Betriebskosten p. a. ermittelt. Die Kapitalwiedergewinnung wird dabei – wie in Abschnitt 8.2 hergeleitet – mit einem **standortspezifischen, risikoadjustierten WACC** (5,5–9,5 %, nicht mehr pauschal 7 %) berechnet.

Standort	PV-/Wind-Mix (Nameplate)	Kapazitätsfaktor (blend)	WACC	Nameplate	CAPEX (inkl. Land)	LCOE
Norwegen	≈15 % PV / 85 % Wind	≈ 37,0 %	5,5 %	≈ 5,7 GW	≈ 10,3 Mrd. US\$	7,07 ct\$/kWh
Spanien	≈65 % PV / 35 % Wind	≈ 25,1 %	6,0 %	≈ 8,0 GW	≈ 11,2 Mrd. US\$	8,25 ct\$/kWh
Marokko	≈50 % PV / 50 % Wind	≈ 36,5 %	9,5 %	≈ 5,9 GW	≈ 9,4 Mrd. US\$	7,93 ct\$/kWh
Chile	≈75 % PV / 25 % Wind	≈ 29,5 %	7,0 %	≈ 7,0 GW	≈ 9,6 Mrd. US\$	7,26 ct\$/kWh
USA-Texas	≈40 % PV / 60 % Wind	≈ 37,4 %	6,5 %	≈ 5,2 GW	≈ 8,8 Mrd. US\$	6,93 ct\$/kWh
Australien	≈50 % PV / 50 % Wind	≈ 32,0 %	6,0 %	≈ 6,7 GW	≈ 10,3 Mrd. US\$	7,12 ct\$/kWh
System-Mittel (gewichtet)	—	—	≈6,7 %	≈ 38,9 GW	≈ 59,6 Mrd. US\$	7,43 ct\$/kWh

Tab. 8a: Validierte, risiko-WACC-basierte LCOE-Berechnung für den Eigenbetrieb je Standort, inklusive Grundstückskosten (Nameplate-Bedarf inklusive Überbauungsfaktor zur Deckung der 2-GW-IT-Last; Herleitung der WACC-Sätze in Abschnitt 8.2, der Grundstückskosten in Abschnitt 7.1a).




Abb. 6: Validierter Standort-LCOE bei Eigeninvestition (CAPEX-Annuität inkl. Grundstückskosten bei standortspezifischem Risiko-WACC von 5,5–9,5 % über 20 Jahre + 2 % O&M + Wind-Pachtkosten) im Vergleich zu allgemeinen Industriestrom-Referenzwerten für die USA und die EU (*IEA, Electricity 2026: EU-Industriestrompreise 2025 im Schnitt rund doppelt so hoch wie in den USA und ca. 50 % höher als in China).

Bei einem gewichteten System-LCOE von rund **7,43 ct\$/kWh** ergeben sich jährliche Stromkosten von **≈ 6,9 Mrd. US\$ pro Jahr** (92,5 TWh × 7,43 ct\$/kWh). Dieser Wert liegt **rund 32 % über** der zuvor in einer ersten, vereinfachten PPA-Annahme genannten Größenordnung von 5,6 ct\$/kWh bzw. 5,2 Mrd. US\$/Jahr: Günstige PPA-Angebote spiegeln oft optimierte Grossprojekte mit Steuervergünstigungen, günstigerer Fremdfinanzierung oder Drittbetreiber-Skaleneffekten wider, während die hier vorgenommene Eigenbetriebs-Kalkulation den vollen Kapitalbedarf (inkl. der für hohe Verfügbarkeit nötigen Nameplate-Überbauung, Batteriespeicher, länderspezifischer Kapitalkostenprämien und Grundstückskosten) realistisch bepreist. Bemerkenswert ist zudem, dass sich die Rangfolge der Standorte gegenüber der ursprünglichen PPA-Schätzung ändert: **USA-Texas wird zum günstigsten Standort** (gute Ressourcenkombination, niedriges Kapitalkostenrisiko und moderate Grundstückspreise), während **Marokko trotz sehr guter PV-/Windressource und günstigstem Grundstückspreis durch den Länderrisikoaufschlag (Abschnitt 8.2) im Mittelfeld bleibt** und **Chile trotz der weltweit besten PV-Einstrahlung ebenfalls nicht das billigste System ist**, da dort mehr Nameplate-Leistung und Batteriekapazität nötig sind, um auch Schwachwind-Phasen zu überbrücken.

Auch nach dieser Korrektur nach oben bleibt der Systempreis deutlich unter den allgemeinen Industriestrom-Referenzwerten: EU-Industriestrompreise für energieintensive Grossabnehmer lagen 2025 laut IEA im Schnitt etwa doppelt so hoch wie in den USA. Eurostat beziffert den nicht-privaten Strompreis in der zweiten Jahreshälfte 2025 in der EU auf durchschnittlich rund 16–27 ct\$/kWh (umgerechnet), mit grosser Spannweite zwischen z. B. Finnland (~8,1 ct\$/kWh) und Irland (~27,5 ct\$/kWh). Der validierte HELIOS-Systempreis von 7,43 ct\$/kWh liegt damit weiterhin klar unter dem EU-Durchschnitt (~12,4 ct\$/kWh) und moderat über dem US-Industriestrompreis (~6,3 ct\$/kWh) – die Differenz hat sich durch die Kapitalkosten- und Grundstückskostenkorrektur gegenüber der ersten Schätzung verringert.

7.1a Erforderliche Grundstücksflächen und Grundstückskosten

Für jeden Standort wird die benötigte Fläche für PV, Wind und den Rechenzentrums-Campus selbst geschätzt. PV-Anlagen benötigen nach Branchenbenchmarks (NREL Land-Use-Studien) rund 3 ha/MW; Onshore-Windparks benötigen als **Bruttoprojektfläche** (inkl. nötigem Turbinenabstand) rund 35 ha/MW, wovon jedoch typischerweise nur 1–3 % tatsächlich versiegelt bzw. exklusiv genutzt werden – die übrige Fläche bleibt meist landwirtschaftlich nutzbar und wird über **Pacht-/Nutzungsentgelte** statt Grundstückskauf vergütet (hier angesetzt: 10.000 US\$/MW/Jahr, ein für Onshore-Windparks branchenüblicher Pachtsatz). Für den Rechenzentrums-Campus selbst (Gebäude, Kühlung, Umspannwerk, Wasseraufbereitung, Personal- und Sicherheitsinfrastruktur, Erweiterungsflächen) wird pauschal eine Fläche von 150 ha je Standort angesetzt. PV-Flächen und die RZ-Campusfläche werden als **Grundstückskauf** zu lokalen Preisen in die CAPEX (Tab. 8a) eingerechnet.

Standort	Lokaler Bodenpreis	Land-CAPEX (PV+RZ, Kauf)	Wind-Pacht (OPEX)
Norwegen	≈ 6.000 US\$/ha	≈ 16,3 Mio. US\$	≈ 48,6 Mio. US\$/Jahr
Spanien	≈ 5.000 US\$/ha	≈ 78,6 Mio. US\$	≈ 27,9 Mio. US\$/Jahr
Marokko	≈ 1.000 US\$/ha	≈ 9,1 Mio. US\$	≈ 29,7 Mio. US\$/Jahr
Chile	≈ 600 US\$/ha	≈ 9,6 Mio. US\$	≈ 17,6 Mio. US\$/Jahr
USA-Texas	≈ 4.000 US\$/ha	≈ 25,7 Mio. US\$	≈ 31,3 Mio. US\$/Jahr
Australien	≈ 1.200 US\$/ha	≈ 12,2 Mio. US\$	≈ 33,5 Mio. US\$/Jahr
Summe	—	≈ 151 Mio. US\$	≈ 188,5 Mio. US\$/Jahr

Tab. 8b: Grundstückskosten je Standort (Flächenbedarf siehe Tab. 2a in Kapitel 3.1). Bodenpreise sind grobe, standortklassenbezogene Schätzungen für ländliches/wüstennahes Gewerbeland (keine Einzelparzellen-Bewertung). Der Land-CAPEX-Betrag (≈151 Mio. US\$ systemweit) ist bereits in der CAPEX-Spalte von Tab. 8a enthalten; die Wind-Pacht (≈189 Mio. US\$/Jahr systemweit) ist als laufende Betriebskost separat in den OPEX-Zahlen ab Abschnitt 7.1 und Kapitel 8.4 berücksichtigt.

Land- und Pachtkosten sind mit rund 151 Mio. US\$ CAPEX (≈0,25 % der Gesamt-CAPEX) und rund 189 Mio. US\$/Jahr Pacht (≈14 % der O&M-Kosten) **klein im Verhältnis zu den Anlagen- und Kapitalkosten, aber nicht vernachlässigbar** – insbesondere die Windpacht ist bereits in Tab. 8a eingepreist und erklärt einen Teil der Verschiebung der Standort-Rangfolge gegenüber einer reinen Anlagen-CAPEX-Betrachtung.

7.2 Kosten privater Glasfaserverbindungen zwischen Cluster-Standorten

Da die Standortpaare Spanien↔Marokko und Chile↔USA-Texas mit rund 2 Verlagerungen pro Tag (≈ 730/Jahr) die mit Abstand häufigsten Verlagerungsoperationen aufweisen, wird für diese beiden Verbindungen jeweils eine **dedizierte private Glasfaserstrecke** (Dark Fiber / gemietete Wellenlängenkapazität, ≥ 400 Gbit/s) statt öffentlicher Internet-Transitkapazität angesetzt. Dies senkt Latenz und erhöht Zuverlässigkeit und Vertraulichkeit der Checkpoint-Übertragung erheblich.

Verbindung	Distanz	Kapazität	Kostenschätzung*	Jahreskosten*
Spanien ↔ Marokko	≈ 1.650 km	400 Gbit/s (terrestrisch)	≈ 2.376 US\$/km/Jahr	≈ 3,9 Mio. US\$/Jahr
Chile ↔ USA-Texas	≈ 8.200 km	400 Gbit/s (Land + Seekabelanteil)	≈ 3.780 US\$/km/Jahr	≈ 31,0 Mio. US\$/Jahr
Summe private Glasfaser	—	—	—	≈ 34,9 Mio. US\$/Jahr

Tab. 6: Geschätzte Kosten dedizierter privater Glasfaserverbindungen. *Marktordnungsgrößen (Größenordnungsschätzung auf Basis branchenüblicher Preisspannen für gemietete Dark-Fiber-/Wellenlängenkapazität; keine Einzelquelle, da standort- und vertragspezifisch stark variierend). Die Anker-Standorte Norwegen und Australien werden mangels häufiger Verlagerung über gemietete Standard-Backbone-Kapazität angebunden.

Die Glasfaserkosten von rund 35 Mio. US\$/Jahr entsprechen weniger als 1 % der geschätzten jährlichen Stromkosten des Gesamtsystems (Abschnitt 6.1) und sind damit ökonomisch nachrangig, aber technisch

notwendig, um die in Abschnitt 5.3 beschriebenen Verlagerungsfrequenzen mit ausreichend niedriger Latenz und garantierter Bandbreite zu realisieren.

7.3 Sicherheitskosten am Standort mit erhöhtem Risiko

Für den Standort Marokko/Dakhla wird aufgrund des in Abschnitt 4 beschriebenen ungelösten Territorialkonflikts um die Westsahara zusätzlich zum zivilen Objektschutz eine **bewaffnete Schutztruppe von 1.500 Personen** inkl. Drohnenabwehr und Kurzstrecken-Raketenabwehr (Point Defense) kalkuliert. Die folgenden Kostenpositionen sind Grössenordnungsschätzungen auf Basis öffentlich bekannter Kostenstrukturen privater Sicherheits-/Söldnerdienstleister und militärischer Point-Defense-Systeme:

Position	Annahme	Kosten p.a.*
Personal (1.500 Mann, bewaffnete Schutztruppe)	≈ 97.000–130.000 US\$/Kopf/Jahr (Sold, Ausrüstung, Unterkunft, Rotation)	≈ 162 Mio. US\$
Drohnenabwehrsystem (Sensorik + Effektoren)	mehrschichtiges Counter-UAS-System für ein Areal dieser Grösse	≈ 16 Mio. US\$
Kurzstrecken-Raketen-/Point-Defense-System	1–2 Batterien inkl. Betrieb, Wartung, Munition	≈ 43 Mio. US\$
Basisinfrastruktur (Unterkünfte, Logistik, Perimeter)	einmalig amortisiert über 10 Jahre	≈ 11 Mio. US\$
Summe Sicherheitskosten Standort Marokko	—	≈ 232 Mio. US\$/Jahr

Tab. 7: Geschätzte jährliche Sicherheitskosten für den Standort mit erhöhtem Risiko (Marokko/Dakhla). *Grobe Grössenordnungsschätzung, keine belastbare Einzelquelle – vergleichbar dimensionierte private Sicherheitskräfte in Konfliktregionen bewegen sich erfahrungsgemäss in ähnlichen Grössenordnungen; tatsächliche Kosten hängen stark von Vertragsgestaltung, Nationalität der Kräfte und Ausrüstungsstandard ab.

Diese Sicherheitskosten erhöhen die Gesamtbetriebskosten des Standorts Marokko spürbar (rund 232 Mio. US\$ p. a. entsprechen bei ≈ 16,1 TWh Jahresverbrauch dieses einzelnen 2-GW-Standorts (Tab. 8a) einem Aufschlag von rund **1,4 ct\$/kWh** auf den lokalen Systemstrompreis) und sollten in einer Investitionsentscheidung dem stabileren, aber weniger ertragreichen Alternativstandort (z. B. Spanien als alleinigem EMEA-Standort ohne Marokko-Partner) gegenübergestellt werden.

8. Wirtschaftlichkeitsberechnung: PROJECT HELIOS vs. Gaskraftwerke mit CO2-Kompensation

Das Kostenmodell in Kapitel 7 unterstellte vereinfachend günstige PPA-Strompreise (Stromabnahmeverträge mit Dritten). Für eine belastbare Wirtschaftlichkeitsbetrachtung wird in diesem Kapitel stattdessen von **Eigeninvestitionen** in die PV-, Wind- und Batterieanlagen im Rahmen von PROJECT HELIOS ausgegangen und dem **Alternativszenario** gegenübergestellt, dass an allen sechs Standorten stattdessen Gaskraftwerke (Combined-Cycle-Gasturbinen, CCGT) mit entsprechender Leistung errichtet und deren CO2-Emissionen vollständig durch Zertifikate kompensiert würden.

8.1 Investitionskosten (CAPEX) – Prüfung der Renewables-Kostenannahmen

Aktuelle Marktdaten (2025/2026) zeigen für die relevanten Technologien folgende Investitionskosten-Bandbreiten: Utility-Scale-PV liegt je nach Region bei rund 0,76–0,97 Mio. US\$/MW; Onshore-Wind bei rund 1,30–1,62 Mio. US\$/MW; Batteriespeicher (4h-Duration, schlüsselfertig) sind 2025 stark gefallen und liegen je nach Beschaffungsmarkt zwischen rund 135 und 178 US\$/kWh (BNEF-Globaldurchschnitt 2024: 178 US\$/kWh; wettbewerbsintensive Ausschreibungen wie z. B. in Italien 2025 erreichen bereits rund 130–135 US\$/kWh). Da ein Rechenzentrums-Standort eine sehr hohe Versorgungssicherheit benötigt, wird – anders als bei einem gewöhnlichen Netzeinspeiseprojekt – ein deutlicher **Overbuild-Faktor** der Erneuerbaren-Nameplate-Leistung gegenüber der 2-GW-IT-Last angesetzt (analog zu realen '24/7 Carbon-Free Energy'-Beschaffungsprogrammen von Hyperscalern), um auch bei durchschnittlichen Kapazitätsfaktoren von 25–45 % eine hohe Deckung zu erreichen.

Komponente	Kosten je Einheit*	Kommentar
PV-Nameplate	≈ 0,92 Mio. US\$/MW	Utility-Scale, einachsrig nachgeführt
Wind-Nameplate (onshore)	≈ 1,51 Mio. US\$/MW	inkl. Fundament, Netzanschluss
Batteriespeicher	≈ 178.000 US\$/MWh	schlüsselfertiges 4h+-BESS-Projekt, BNEF-Globaldurchschnitt 2024

Tab. 9: Angesetzte CAPEX-Sätze je Technologie. *Marktbandbreiten 2025/2026 (LBNL Utility-Scale Solar 2025; Wood Mackenzie LCOE-Report 2025; Ember Energy Battery-Storage-Report 2026, umgerechnet zu 1 EUR = 1,08 US\$); Mittelwerte der jeweiligen Bandbreite angesetzt.

Der tatsächliche Nameplate-Bedarf variiert je Standort deutlich mit dem lokalen PV-/Wind-Mix und den jeweiligen Kapazitätsfaktoren (siehe Tab. 8a in Abschnitt 7.1, wo diese CAPEX-Sätze bereits standortspezifisch angewendet wurden). Zusammen mit den Grundstückskosten aus Abschnitt 7.1a (Tab. 8b) ergibt sich daraus ein Gesamt-CAPEX von ≈ **59,6 Mrd. US\$** für das Sechs-Standorte-System – der in Abschnitt 7.1 hergeleitete Wert wird hier für die Wirtschaftlichkeitsrechnung übernommen.

8.2 Kapitalkosten (WACC) und länderspezifische Risikoprämien

Da PV-, Wind- und Batterieanlagen fast ausschliesslich **kapitalintensiv** sind (hoher CAPEX-Anteil, praktisch keine Brennstoffkosten), reagiert ihr LCOE sehr empfindlich auf die angenommenen Kapitalkosten. Als Basis-Kapitalstruktur wird ein für Infrastrukturprojekte übliches Verhältnis von 70 % Fremdkapital (Projektfinanzierung, Zinssatz $\approx 5,5$ % vor Steuern) zu 30 % Eigenkapital (Renditeerwartung ≈ 11 %) angesetzt, was einen nominalen Basis-WACC von rund **6,0–6,5 %** ergibt. Auf diese Basis wird je Standort ein **Länderrisikoaufschlag** angewendet, der sich primär an der in Kapitel 4 bewerteten politischen und Investitionssicherheit orientiert – mit einer wichtigen Einschränkung: die dortige GPI-Einstufung bildet gesellschaftliche Friedfertigkeit ab, nicht zwangsläufig die Finanzierungsfähigkeit eines Standorts. So verfügen die USA trotz des niedrigen GPI-Rangs (128/163, Kapitel 4) weiterhin über die tiefsten und liquidesten Kapitalmärkte der Welt, weshalb dort kein nennenswerter Risikoaufschlag angesetzt wird. Für Marokko/Dakhla wird dagegen wegen des ungelösten Territorialkonflikts und der in Abschnitt 7.3 beschriebenen Sicherheitslage ein spürbarer Aufschlag von rund 3–3,5 Prozentpunkten (vergleichbar mit Risikoprämien für Projekte in Grenzregionen mit Konfliktpotenzial) angesetzt.

Standort	Basis-WACC	Risikoaufschlag	Standort-WACC	Begründung
Norwegen	5,5 %	0,0 pp	5,5 %	sehr hohe politische/institutionelle Stabilität (Kapitel 4)
Spanien	6,0 %	0,0 pp	6,0 %	Teil der stabilsten Weltregion (West-/Mitteleuropa)
Marokko (Dakhla)	6,0 %	+3,5 pp	9,5 %	ungelöster Territorialkonflikt, erhöhte Sicherheitslage (Abschnitt 7.3)
Chile	6,0 %	+1,0 pp	7,0 %	regional verbessernd, aber noch nicht auf OECD-Kern-Niveau
USA-Texas	6,5 %	0,0 pp	6,5 %	tiefe, liquide Kapitalmärkte trotz niedrigerem GPI-Rang
Australien	6,0 %	0,0 pp	6,0 %	sehr hohe politische/institutionelle Stabilität (Kapitel 4)

Tab. 9a: Herleitung der standortspezifischen WACC-Sätze aus Basis-Kapitalstruktur und Länderrisikoaufschlag. Eigene Einschätzung, keine formale Länderrisiko-Ratingquelle; dient der Grössenordnungseinschätzung.




Abb. 7a: Sensitivität des LCOE gegenüber dem Kapitalkostensatz (WACC), im Vergleich zwischen PROJECT HELIOS (kapitalintensiv, ≈ 100 % des LCOE ist Kapitalkosten + O&M) und der Gaskraftwerk-Alternative (kapitalleicht, dominiert von laufenden Brennstoff- und CO₂-Kosten). Über die dargestellte Bandbreite von 3–13 % WACC schwankt der HELIOS-LCOE um rund 4,8 ct\$/kWh, der Gas-LCOE dagegen nur um rund 1,5 ct\$/kWh.

Diese Asymmetrie ist ein zentrales Ergebnis der Kapitalkostenbetrachtung: **Erneuerbare Eigenanlagen sind ein Kapitalkosten-Wette, Gaskraftwerke eine Brennstoffpreis-Wette.** Für PROJECT HELIOS ist die Verfügbarkeit günstiger, langfristiger Projektfinanzierung (niedriger WACC) daher wirtschaftlich mindestens so wichtig wie die reine Standort-Ressourcenqualität (PV-/Windertrag) – ein zusätzliches Argument, politisch/institutionell stabile Standorte auch dann zu bevorzugen, wenn ihre Erneuerbaren-Ressource nominell nicht die weltweit beste ist.

8.3 Gas-Alternative: Investitions- und Betriebskosten

Für Combined-Cycle-Gaskraftwerke (CCGT) werden aktuelle Projektkosten von rund 1.190–2.160 US\$/kW zugrunde gelegt (Branchenanalysen für 2026–2027 in Betrieb gehende Projekte); es wird ein Mittelwert von 1.600 US\$/kW sowie eine Nameplate-Leistung von 2,2 GW je Standort (10 % Reservemarge gegenüber der 2-GW-IT-Last) angenommen. Der CO₂-Ausstoss moderner CCGT-Anlagen liegt bei rund 0,35 kg CO₂/kWh. Für die 'vollständige CO₂-Kompensation' wird ein Zertifikatspreis von 85 US\$/t CO₂ angesetzt – orientiert an einem compliance-nahen Preisniveau (vergleichbar dem EU-ETS-Preisband der letzten Jahre), nicht an günstigen freiwilligen Offsets von teils nur 16–27 US\$/t, da diese qualitativ oft nicht als vollständige, dauerhafte Kompensation gelten.

Position je Standort	Annahme	Wert
CAPEX Gaskraftwerk	2,2 GW × 1.600 US\$/kW	≈ 3,52 Mrd. US\$
Jahreserzeugung	2,2 GW × 8.760 h × 90 % Kapazitätsfaktor	≈ 17,3 TWh/Jahr
Brennstoff- & Betriebskosten (ohne CO ₂)	≈ 5,9 ct\$/kWh	≈ 1.023 Mio. US\$/Jahr
CO ₂ -Emissionen	0,35 kg/kWh × 17,3 TWh	≈ 6,07 Mio. t/Jahr
CO ₂ -Kompensationskosten	6,07 Mio. t × 85 US\$/t	≈ 516 Mio. US\$/Jahr
Summe OPEX je Standort (Brennstoff+CO ₂)	—	≈ 1.539 Mio. US\$/Jahr
Summe Gesamtsystem: CAPEX (6 Standorte)	—	≈ 21,1 Mrd. US\$
Summe Gesamtsystem: OPEX p. a. (6 Standorte)	—	≈ 9,24 Mrd. US\$/Jahr

Tab. 10: Investitions- und Betriebskosten der Gaskraftwerk-Alternative inkl. vollständiger CO₂-Kompensation. Größenordnungsschätzung auf Basis öffentlicher Branchendaten (GridLab Gas-Turbine-Costs-Report 2025, Thundersaid Energy Gas-Power-Analyse 2025).

8.4 Wirtschaftlichkeitsvergleich (TCO, NPV und Payback) unter Kapitalkosten-Berücksichtigung




Abb. 8: Kumulierte Gesamtkosten (CAPEX + laufende OPEX) über 20 Betriebsjahre im Vergleich. PROJECT HELIOS erfordert eine deutlich höhere Anfangsinvestition, amortisiert diese jedoch durch den Wegfall von Brennstoff- und CO2-Kompensationskosten innerhalb weniger Jahre.

Kennzahl	PROJECT HELIOS	Gas + CO2-Kompensation
CAPEX (Gesamtsystem, inkl. Grundstücke)	≈ 59,6 Mrd. US\$	≈ 21,1 Mrd. US\$
OPEX p. a. (Gesamtsystem)	≈ 1,38 Mrd. US\$/Jahr (O&M + Wind-Pacht)	≈ 9,24 Mrd. US\$/Jahr (Brennstoff + CO2)
TCO nach 20 Jahren	≈ 87,2 Mrd. US\$	≈ 205,8 Mrd. US\$
Mehrinvestition HELIOS (CAPEX-Differenz)	≈ 38,5 Mrd. US\$	—
Jährliche OPEX-Einsparung durch HELIOS	≈ 7,86 Mrd. US\$/Jahr	—
Amortisationsdauer der Mehrinvestition (Payback)	≈ 4,9 Jahre	—
Netto-Ersparnis über 20 Jahre	≈ 118,7 Mrd. US\$	—

Tab. 11: Undiskontierter Wirtschaftlichkeitsvergleich (Kosten in nominalen US\$, ohne Abzinsung). CAPEX/LCOE gemäss der validierten, standortspezifischen Berechnung aus Abschnitt 7.1/7.1a/8.1/8.2. Die Mehrinvestition in die HELIOS-Eigenanlagen amortisiert sich modellhaft nach rund 4,9 Betriebsjahren; über den 20-jährigen Betrachtungszeitraum ergibt sich eine Netto-Ersparnis in der Grössenordnung von rund 119 Mrd. US\$ gegenüber der Gas-Alternative.

Da Kapitalkosten den Wert künftiger Einsparungen mindern (ein in 15 Jahren eingesparter Dollar ist heute weniger wert als ein Dollar, der heute investiert werden muss), wird die Betrachtung zusätzlich mit einem **Kapitalwert (Net Present Value, NPV)** bei einem einheitlichen Diskontsatz von 7 % (nahe am gewichteten HELIOS-System-WACC aus Abschnitt 8.2) ergänzt:

Kennzahl (Diskontsatz 7 %, 20 Jahre)	Wert
Barwert (PV) der Gesamtkosten PROJECT HELIOS	≈ 74,2 Mrd. US\$
Barwert (PV) der Gesamtkosten Gas + CO2-Kompensation	≈ 119,0 Mrd. US\$
Kapitalwert (NPV) des Vorteils von HELIOS gegenüber Gas	≈ + 44,8 Mrd. US\$
Interner Zinsfuss (IRR) der Mehrinvestition in HELIOS	≈ 20 % p. a.

Kennzahl (Diskontsatz 7 %, 20 Jahre)	Wert
Diskontierte Amortisationsdauer (Discounted Payback)	≈ 6,2 Jahre

Tab. 11a: Kapitalwert- und Renditekennzahlen der Mehrinvestition in PROJECT HELIOS gegenüber der Gas-Alternative. Selbst unter Berücksichtigung der Kapitalkosten (Diskontierung mit 7 % p. a.) bleibt der NPV klar positiv und die IRR der Mehrinvestition liegt weit über üblichen Kapitalkostensätzen für Infrastrukturprojekte (6–10 %).




Abb. 9: Jährliche CO2-Emissionen im Vergleich. PROJECT HELIOS verursacht nur Lebenszyklus-/Herstellungsemissionen (Produktion & Errichtung von PV-Modulen, Windturbinen und Batterien, grob mit 20–25 g CO2/kWh über die Lebensdauer amortisiert angenommen), während die Gas-Alternative rund 36,4 Mio. t CO2/Jahr direkt emittiert, die erst nachträglich durch Zertifikate kompensiert werden müssen.

Diese Berechnung berücksichtigt nun sowohl die standortspezifischen Kapitalkosten in der LCOE-Bildung (Abschnitt 8.2) als auch eine klassische Kapitalwertrechnung für den Gesamtvergleich, bleibt aber ein **vereinfachtes Modell** (einheitlicher Diskontsatz für beide Optionen, keine Steuereffekte, Restwerte, Refinanzierungen während der Laufzeit oder Preissteigerungen berücksichtigt). Wesentliche Annahmen mit hohem Einfluss auf das Ergebnis bleiben der CO2-Kompensationspreis (85 US\$/t) und der Erdgaspreis (≈5,9 ct\$/kWh); ein deutlich niedrigerer CO2-Preis oder Erdgaspreis würde die Amortisationsdauer der Eigenanlagen verlängern, ohne jedoch das grundsätzliche Bild – deutlich niedrigere Lebenszykluskosten von HELIOS gegenüber der Gas-Alternative, auch unter Einpreisung der Kapitalkosten – umzukehren, da bereits der reine Brennstoffkostenanteil ohne CO2-Aufschlag (≈1.023 Mio. US\$/Jahr je Standort) allein die OPEX-Differenz weitgehend erklärt.

9. Rechnerarchitektur: notwendige Unterschiede zwischen Training und Inferenz

Die in diesem Konzept beschriebene Infrastruktur ist explizit für die **Trainingsphase** ausgelegt (vgl. Abschnitt 1.1). Eine für die **Inferenzphase** optimierte Infrastruktur unterscheidet sich davon in mehreren grundlegenden technischen Dimensionen:

Dimension	Training	Inferenz
Rechenmuster	Synchrones, eng gekoppeltes Verteiltraining über tausende Beschleuniger (Daten-/Tensor-/Pipeline-Parallelismus, All-Reduce-Gradientenabgleich)	Weitgehend unabhängige, parallele Einzelanfragen (embarrassingly parallel); Batching mehrerer Nutzeranfragen zur Effizienzsteigerung
Interconnect-Anforderung	Sehr hohe Bandbreite, sehr niedrige Latenz zwingend erforderlich (NVLink/NVSwitch intra-Node, InfiniBand/RoCE inter-Node, hunderte Gbit/s bis Tbit/s aggregiert)	Deutlich geringere Interconnect-Anforderungen; einzelne Server/kleine Cluster oft ausreichend
Speicherprofil	Hoher HBM-Bedarf für Aktivierungen, Gradienten und Optimierer-Zustände (Adam-Momente)	Dominiert durch KV-Cache-Speicher pro aktiver Sitzung; Modellgewichte oft quantisiert (INT8/FP8/INT4)
Auslastung/Verfügbarkeit	Nahezu 100 % Dauerlast über Wochen/Monate an wenigen, sehr grossen Standorten	Stark schwankende, tageszeit-/nutzerabhängige Last; viele kleinere, verteilte Standorte mit Autoscaling
Geografische Anforderung	Standortwahl primär nach Energieverfügbarkeit/-kosten; Nähe zum Nutzer irrelevant, da kein Endnutzer-Interaktionslatenz-Bezug	Standortwahl primär nach Nutzernähe (Latenz < 100–300 ms Rundlaufzeit für interaktive Anwendungen); Energieverfügbarkeit sekundär
Fehlertoleranz	Checkpointing zur Wiederherstellung nach Ausfällen; Ausfall eines Knotens gefährdet ggf. den gesamten Trainingslauf	Einzelner Anfrage-Ausfall betrifft nur diese eine Anfrage; hohe Redundanz durch viele unabhängige Instanzen
Typische Hardware-Optimierung	Maximale FLOPs/US\$ bei grossen Matrixmultiplikationen, hohe Speicherbandbreite je Chip	Maximaler Durchsatz/US\$ und minimale Latenz je Token, oft spezialisierte Inferenz-Beschleuniger mit niedrigerer Präzision

Tab. 12: Architektonische Unterschiede zwischen Trainings- und Inferenz-Infrastruktur.

Diese Unterschiede erklären, warum das PROJECT-HELIOS-Konzept – wenige, sehr grosse (2 GW), eng vernetzte Standorte mit seltenen, aber grossen Checkpoint-Verlagerungen (Kapitel 5–6) – für die Trainingsphase sinnvoll ist, für die Inferenzphase jedoch **nicht direkt übertragbar** wäre: Ein reines Kopieren der HELIOS-Architektur auf die Inferenz würde die Latenzanforderungen der Endnutzer-Interaktion verletzen und liesse die vorhandene geografische Nähe zu Nutzerzentren (Ballungsräume) ungenutzt.

10. Szenario: Globales Load-Balancing der Inferenzlast über Renewable-Standorte

Da die Inferenzphase gemäss Abschnitt 1.1 mit geschätzt 70–85 % den weitaus grösseren Anteil am Lebenszyklus-Stromverbrauch eines LLMs ausmacht, stellt sich die Frage, ob sich das wirtschaftliche und ökologische Gesamtbild deutlich verbessert, wenn – zusätzlich zum Training – auch ein Teil der Inferenzlast aktiv zu Standorten mit hoher Erneuerbaren-Verfügbarkeit geroutet würde ('Follow-the-Renewables' auch für Inferenz).

10.1 Nicht die gesamte Inferenzlast ist gleichermassen verlagerbar

Wie in Kapitel 9 dargelegt, ist ein wesentlicher Teil der Inferenzlast – insbesondere interaktive, latenzkritische Anwendungen wie Chat-Assistenten – an die Nähe zum Endnutzer gebunden und kann nicht beliebig zu weit entfernten, aber energetisch günstigeren Standorten verlagert werden, ohne die Nutzererfahrung spürbar zu verschlechtern. Ein wachsender Teil der Inferenzlast ist jedoch **latenztolerant und asynchron**: umfangreiche Batch-Verarbeitung (Dokumentenanalyse, Offline-Zusammenfassungen), nicht-interaktive Agenten-Workflows mit mehrstufiger Verarbeitung sowie versetzt ausgelieferte API-Anfragen ohne harte Echtzeitanforderung. Aktuelle Marktbeobachtungen verweisen auf einen wachsenden Anteil solcher 'agentischer', mehrstufiger und damit latenztoleranterer Arbeitslasten am gesamten KI-Anfragevolumen.

Inferenz-Kategorie	Anteil (Schätzung)	Latenzanforderung	Verlagerbar zu Renewable-Standorten?
Interaktiver Chat/Assistent (Echtzeit)	≈ 45–55 %	sehr hoch (< 1–2 s)	Nein – muss nutzernah bleiben
API-Anfragen mit moderater Echtzeitanforderung	≈ 20–25 %	mittel (Sekunden)	Teilweise – regionale statt globale Verlagerung
Batch-/Offline-Verarbeitung, Agenten-Workflows, Trainingsdaten-Aufbereitung	≈ 20–35 % (wachsend)	niedrig (Minuten bis Stunden)	Ja – global verlagerbar

Tab. 13: Grobe Segmentierung der Inferenzlast nach Latenzanforderung und Verlagerbarkeit (eigene Schätzung, keine Einzelquelle – Marktanteile variieren je Anbieter und Anwendungsfall stark).

10.2 Auswirkung auf das Gesamtbild

Würde der latenztolerante, global verlagerbare Anteil der Inferenzlast (Tab. 13, unterste Zeile, grob 20–35 % der gesamten Inferenzlast) zusätzlich zur Trainingslast über ein globales Load-Balancing an Standorte mit hoher Erneuerbaren-Verfügbarkeit geroutet, würde sich das Gesamtbild **deutlich, aber nicht vollständig** verändern:

- Da Inferenz insgesamt 70–85 % des Lebenszyklus-Stromverbrauchs ausmacht (gegenüber 15–30 % für Training), hätte selbst eine partielle Verlagerung eines Viertels bis Drittels der Inferenzlast auf Erneuerbaren-Standorte in absoluten Zahlen einen grösseren Hebel auf den Gesamt-Erneuerbaren-Anteil des Systems als jede weitere Optimierung der reinen Trainings-Infrastruktur.
- Dies würde jedoch **keine Erweiterung der bestehenden 6 HELIOS-Trainingsstandorte** bedeuten, sondern ein **separates, zusätzliches Netzwerk** kleinerer, stärker verteilter Inferenz-Rechenzentren erfordern – näher an Nutzerzentren, aber ebenfalls mit lokaler PV-/Windanbindung, ergänzt um eine intelligente Routing-Schicht, die pro Anfrage zwischen 'nutzernah, latenzkritisch' und 'global, erneuerbar-optimiert' unterscheidet.
- Die Kosten- und CO2-Vorteile aus Kapitel 8 (Eigeninvestition in Erneuerbare vs. Gaskraftwerke) gelten für ein solches Inferenz-Netzwerk grundsätzlich analog, jedoch mit anderen Stückzahlen: viele kleinere Standorte statt weniger sehr grosser – mit entsprechend anderen Skaleneffekten bei CAPEX pro MW und einem höheren Anteil an Netzanschluss- und Grundstückskosten je Standort.
- Ein Zielkonflikt bleibt bestehen: menschliche Nutzungsmuster (Tagesrhythmus, Abendspitzen) korrelieren nicht zwangsläufig mit lokaler Solarverfügbarkeit – ein Grossteil der Chat-Nutzung erfolgt abends, wenn die

PV-Erzeugung bereits sinkt. Für den latenztoleranten, global verlagerbaren Lastanteil lässt sich dieser Konflikt jedoch durch zeitliche wie geografische Verlagerung auflösen (Bearbeitung dann, wenn und wo Erneuerbare verfügbar sind), während der latenzkritische Anteil weiterhin auf lokale Batteriespeicher und/oder einen Reststromanteil aus dem öffentlichen Netz angewiesen bleibt.

Fazit: Ja, das Gesamtbild ändert sich spürbar zugunsten der Erneuerbaren-Wirtschaftlichkeit, wenn latenztolerante Inferenzlast global zu Standorten mit ausreichend Erneuerbaren geroutet wird – der Hebel ist wegen des hohen Inferenzanteils am Gesamtverbrauch (Abschnitt 1.1) sogar grösser als bei der reinen Trainingsoptimierung. Dies erfordert jedoch eine eigenständige, architektonisch andere Infrastruktur (Kapitel 9) und lässt sich nur auf den latenztoleranten Teil der Last anwenden – realistisch geschätzt 20–35 % der gesamten Inferenzlast beim heutigen Nutzungsmix, mit steigender Tendenz durch die Zunahme agentischer, asynchroner Workloads.

11. Quellenverzeichnis mit Abstracts

Die folgenden Quellen wurden für die vorliegende Studie recherchiert und ausgewertet. Die Abstracts sind eigene, sinngemässe Zusammenfassungen der jeweiligen Originalquelle (keine wörtlichen Zitate).

IEA (2026): Key Questions on Energy and AI

iea.org/reports/key-questions-on-energy-and-ai

Aktualisierte Prognose der IEA: globaler Rechenzentrums-Stromverbrauch verdoppelt sich von 485 TWh (2025) auf 950 TWh (2030), rund 3 % des globalen Stromverbrauchs. KI-fokussierte Rechenzentren verdreifachen ihren Verbrauch in diesem Zeitraum; die Energieeffizienz pro KI-Aufgabe verbessert sich gleichzeitig historisch beispiellos schnell.

IEA (2025): Energy and AI – Executive Summary

iea.org/reports/energy-and-ai

Grundlagenbericht der IEA zu Energie und KI: Rechenzentrums-Stromverbrauch steigt bis 2030 auf rund 945 TWh und bis 2035 auf rund 1.200 TWh. In den USA übertrifft der Rechenzentrumsstrombedarf bis Ende des Jahrzehnts den gesamten Energiebedarf mehrerer energieintensiver Industriezweige zusammen.

IEA (2026): Electricity 2026 – Prices

iea.org/reports/electricity-2026/prices

Vergleich internationaler Strompreise für energieintensive Industrie: EU-Preise lagen 2025 im Schnitt rund doppelt so hoch wie in den USA und etwa 50 % höher als in China; die Region bleibt damit im internationalen Standortwettbewerb preislich benachteiligt.

Eurostat (2026): Electricity price statistics

[ec.europa.eu/eurostat \(nrg_pc_204/205\)](https://ec.europa.eu/eurostat/nrg_pc_204/205)

Amtliche EU-Statistik zu Strompreisen für Haushalte und Unternehmen. Nicht-Haushaltspreise in der EU reichten in der zweiten Jahreshälfte 2025 von rund 8,1 ct\$/kWh (Finnland) bis 27,5 ct\$/kWh (Irland) (umgerechnet), bei einem EU-Mittel von rund 31 ct\$/kWh für Haushalte.

Brookings (2026): Global energy demands within the AI regulatory landscape

brookings.edu/articles/global-energy-demands-within-the-ai-regulatory-landscape

Analyse zu regionaler Konzentration der Rechenzentrumsnachfrage: lokale Stromnetz-Anteile von Rechenzentren erreichen in Frankfurt bis zu 42 % und in Dublin bis zu 80 % der Gesamtnachfrage, trotz eines globalen Anteils von nur 3–4 %.

AIMultiple (2026): AI Energy Consumption Statistics

aimultiple.com/ai-energy-consumption

Sammlung aktueller Kennzahlen zum KI-Energieverbrauch: Inferenz macht mittlerweile 80–90 % der gesamten KI-Rechenlast aus; das Training eines GPT-4-Grössenordnung-Modells wird auf rund 50 GWh beziffert.

Polytechnique Insights (2025): Generative AI – energy consumption soars

polytechnique-insights.com/en/columns/energy/generative-ai-energy-consumption-soars

Einordnung des Wandels von Trainings- zu Inferenz-dominiertem Energieverbrauch: Meta- und Google-Daten zufolge entfallen inzwischen 60–70 % des KI-Energieverbrauchs auf Inferenz gegenüber 20–40 % auf Training.

ScienceDirect (2025): Green AI techniques for reducing energy consumption in AI systems

sciencedirect.com/science/article/pii/S2590005625002796

Google-Messdaten (2019–2021) zeigen einen Inferenzanteil von rund 60 % gegenüber 40 % Trainingsanteil am gesamten ML-Energieverbrauch; die Studie ordnet den KI-Lebenszyklus in fünf Phasen.

arXiv 2505.23554 (2025): Sustainable Carbon-Aware and Water-Efficient LLM Scheduling in Geo-Distributed Cloud Datacenters

arxiv.org/abs/2505.23554

Framework 'SLIT' zur mehrzieligen Optimierung von LLM-Anfragen über geo-verteilte Rechenzentren hinweg (Latenz, CO₂, Wasserverbrauch, Kosten). Die Studie beziffert den jährlichen Rechenaufwand der Inferenz auf etwa das 25-fache der einmaligen Trainingskosten.

arXiv 2511.16182 (2025): Green Distributed AI Training – Orchestrating Compute Across Renewable-Powered Micro Datacenters

arxiv.org/pdf/2511.16182

Simulationsstudie zu verteiltem KI-Training über fünf mikro-Rechenzentren mit 10-Gbit/s-WAN-Anbindung; leitet anhand einer CAISO-Erzeugungs-Zeitreihe Machbarkeitsschwellen für Checkpoint-Migrationen (60–300 Sekunden) in Abhängigkeit von Checkpoint-Grösse und Bandbreite her.

arXiv 2602.22760 (2026): Distributed LLM Pretraining During Renewable Curtailment Windows

arxiv.org/html/2602.22760

Technischer Bericht zu einem System, das vollständiges LLM-Pretraining über geo-verteilte GPU-Cluster während regionaler Erneuerbaren-Überschussfenster durchführt und elastisch zwischen Einzelstandort- und föderiertem Multi-Standort-Training wechselt.

arXiv 2510.12064 (2025): GeoPipe – a Geo-distributed LLM Training Framework with enhanced Pipeline Parallelism

arxiv.org/pdf/2510.12064

Beschreibt den Trend vom Einzelrechenzentrum zu geo-verteiltem Multi-Rechenzentrum-Training, getrieben durch Energieversorgungsgrenzen, Datenschutzanforderungen und GPU-Fragmentierung über mehrere Cloud-Regionen hinweg.

arXiv 2511.07035 (2025): GoCkpt – Gradient-Assisted Multi-Step Overlapped Checkpointing for Efficient LLM Training

arxiv.org/pdf/2511.07035

Verfahren zur Beschleunigung und Komprimierung von Checkpointing-Vorgängen beim LLM-Training, relevant für die Reduktion der bei Standortverlagerungen zu übertragenden Datenmenge.

Institute for Economics & Peace (2025): Global Peace Index 2025

visionofhumanity.org/resources

Jährlicher Index zur weltweiten Friedfertigkeit von 163 Ländern. Island, Irland, Neuseeland, Österreich und die Schweiz führen das Ranking an; die USA liegen 2025 erstmals hinter Ländern wie Südafrika und Kenia auf Rang 128, Westeuropa bleibt die friedlichste Weltregion.

LBNL (2025): U.S. Utility-Scale Solar 2025 Data Update

emp.lbl.gov (Utility Scale Solar 2025 Edition)

Jährliche Marktstudie des Lawrence Berkeley National Laboratory zu Kosten und Kennzahlen US-amerikanischer Utility-Scale-Solaranlagen; beziffert 2024 einen All-in-Batterie-CAPEX von rund 458 US\$/kWh für hybridisierte PV+Speicher-Projekte und dokumentiert wachsende PV-Batterie-Kopplung.

Wood Mackenzie (2025): Renewable levelized cost of electricity competitiveness reaches new milestone across global markets

woodmac.com/press-releases

Globaler LCOE-Vergleich: Solar-PV mit Nachführung erreicht in der MENA-Region rund 37 US\$/MWh, Onshore-Wind in Europa sinkt von 67,6 US\$/MWh (2024) auf voraussichtlich 56,7 US\$/MWh (2030); Batteriespeicher-Kosten sollen bis 2026 unter 100 US\$/MWh LCOS fallen.

Ember Energy (2026): How cheap is battery storage?

ember-energy.org/latest-insights/how-cheap-is-battery-storage

Auswertung aktueller Batteriespeicher-Ausschreibungen (Italien, Saudi-Arabien, Indien): All-in-Projekt-CAPEX für grosse Langzeit-Speicher liegt Stand Oktober 2025 bei rund 125 US\$/kWh, mit einer daraus resultierenden Levelized Cost of Storage von rund 65 US\$/MWh.

GridLab (2025): The New Reality of Power Generation – An Analysis of Increasing Gas Turbine Costs

gridlab.org (GridLab_Gas-Turbine-Costs-Report)

Analyse realer CCGT-Projektkosten in den USA: für 2026/2027 in Betrieb gehende Projekte werden 1.116–1.427 US\$/kW berichtet, neuere Projekte liegen bereits bei 2.000 US\$/kW und mehr – deutlich über älteren NREL-Prognosen.

Thundersaid Energy (2025): Gas power – levelized costs of combined cycle gas turbines?

thundersaidenergy.com/downloads/gas-to-power-project-economics

Modellrechnung zu CCGT-Wirtschaftlichkeit: Basisfall-LCOE von rund 8 US-Cent/kWh bei einer CO₂-Intensität von 0,35 kg/kWh; grosse Kostenspannbreite (Faktor 3) zwischen den untersuchten Projekten je nach Standort und Marktbedingungen.

arXiv 2406.02252 (2024): Exploring the Efficiency of Renewable Energy-based Modular Data Centers at Scale

arxiv.org/pdf/2406.02252

Untersucht die Vorhersagbarkeit von PV-/Windleistung anhand von ELIA-Netzdaten: der mittlere prozentuale Prognosefehler liegt bei 3-Stunden-Vorhersagen bei rund 8,5–9 %, bei Day-ahead-Vorhersagen bei 18–25 % und bei Wochenvorhersagen bei 44–75 %. Die Studie folgert, dass ein Vorhersagehorizont von einigen Stunden bis zu einem Tag ausreichend Zeit für Workload-Verlagerungen bietet.

Lam et al. / GraphCast (2023, mit Weiterentwicklungen bis 2026): Learning skillful medium-range global weather forecasting, Science

arxiv.org/pdf/2212.12794

KI-basiertes Wettermodell, das bei mittelfristigen Vorhersagehorizonten (u. a. 5–10 Tage) in den meisten Kennzahlen bessere Trefferquoten als das klassische ECMWF-HRES-Modell erzielt. Bei Extremereignissen wie Hitze- und Kältewellen zeigt sich eine bessere Precision-Recall-Bilanz über längere Horizonte, während die Intensität einzelner Extremereignisse weiterhin unsicher bleibt.

Statista (2026): Industrial electricity prices by country 2025

statista.com/statistics/1369634

Ländervergleich industrieller Strompreise: US-Industriestrompreise liegen im internationalen Vergleich deutlich unter dem europäischen Niveau; Norwegen zählt zu den günstigsten europäischen Standorten für gewerbliche Stromabnehmer.

12. Zusammenfassung

PROJECT HELIOS beschreibt ein Konzept für ein global verteiltes, auf erneuerbare Energien ausgelegtes Rechenzentrumsnetzwerk für das Training grosser Sprachmodelle. Sechs Standorte mit je 2 GW IT-Leistung und 12 GWh Batteriekapazität sind in zwei geografische Cluster (EMEA-West: Spanien & Marokko; Amerika: Chile & USA-Texas) sowie zwei Anker-Standorte (Norwegen, Australien) gegliedert. Diese Struktur reduziert die Zahl notwendiger Checkpoint-Verlagerungen gegenüber einer gleichmässig verteilten Architektur deutlich und erlaubt den gezielten Einsatz kostengünstiger, privater Glasfaserverbindungen zwischen den beiden häufig kommunizierenden Standortpaaren. Die modellierte Gesamtverfügbarkeit liegt bei rund 99,95–99,99 %, die validierten, standortspezifisch berechneten Eigenbetriebs-Stromkosten (LCOE mit standortspezifischem Risiko-WACC von 5,5–9,5 %, 20 Jahre, inkl. Grundstückskosten und Wind-Pacht) liegen bei rund 7,4 ct\$/kWh im Systemmittel und damit bei geschätzten Gesamtstromkosten von rund 6,9 Mrd. US\$ pro Jahr – deutlich unter dem EU-Industriestrompreisniveau, aber rund 32 % über einer ersten, optimistischeren PPA-Annahme. Der einzige als sicherheitskritisch eingestufte Standort (Marokko/Dakhla) erfordert zusätzliche jährliche Sicherheitsinvestitionen in der Grössenordnung von rund 232 Mio. US\$ und trägt zusätzlich den höchsten Länderrisikoaufschlag auf die Kapitalkosten (Abschnitt 8.2).

Die vertiefte Wirtschaftlichkeitsbetrachtung (Kapitel 8) zeigt: Bei Eigeninvestition in PV, Wind, Batteriespeicher und Grundstücken liegt die Anfangsinvestition von PROJECT HELIOS mit rund 59,6 Mrd. US\$ deutlich über der einer vergleichbaren Gaskraftwerk-Flotte (rund 21,1 Mrd. US\$). Durch den Wegfall von Brennstoff- und CO₂-Kompensationskosten amortisiert sich die Mehrinvestition jedoch modellhaft bereits nach rund 4,9 Betriebsjahren (diskontiert: rund 6,2 Jahre), mit einer geschätzten Netto-Ersparnis von rund 119 Mrd. US\$ über 20 Jahre bzw. einem Kapitalwert (NPV) von rund +45 Mrd. US\$ bei 7 % Diskontsatz gegenüber der Gas-Alternative mit vollständiger CO₂-Kompensation. Da erneuerbare Eigenanlagen fast ausschliesslich kapitalkostengetrieben sind, während Gaskraftwerke primär brennstoffpreisgetrieben sind, reagiert der HELIOS-LCOE deutlich stärker auf Änderungen der Kapitalkosten als der Gas-LCOE (Abschnitt 8.2) – die Verfügbarkeit günstiger Projektfinanzierung ist für die Wirtschaftlichkeit von HELIOS daher ein zentraler Erfolgsfaktor. Trainings- und Inferenz-Infrastruktur unterscheiden sich architektonisch grundlegend (Kapitel 9): Während Training wenige, sehr grosse, eng vernetzte Standorte ohne Nutzernähe-Anforderung benötigt, ist Inferenz überwiegend latenzkritisch und muss nutzernah erfolgen. Ein globales Load-Balancing der Inferenzlast zu Erneuerbaren-Standorten (Kapitel 10) ist daher nur für den latenztoleranten, asynchronen Teil der Inferenzlast (geschätzt 20–35 %, mit steigender Tendenz durch agentische Workloads) sinnvoll möglich – hätte wegen des hohen Inferenzanteils am Gesamtverbrauch aber einen grösseren absoluten Hebel auf den Erneuerbaren-Anteil des Gesamtsystems als die alleinige Optimierung der Trainings-Infrastruktur.

Alle quantitativen Ergebnisse zu Verlagerungsfrequenzen, Nutzungsraten, Verfügbarkeit und Kosten sind modellbasierte Schätzungen auf Grundlage aktueller Fachliteratur und öffentlicher Marktdaten – nicht das Ergebnis einer Auswertung historischer Betriebsdaten eines real existierenden Systems, da ein solches System bislang nicht öffentlich dokumentiert betrieben wird. Für eine belastbare Investitionsentscheidung wird eine vertiefte, standortspezifische Machbarkeitsstudie empfohlen.