

SCORE — **Smart Cost-Optimized** Recognition & Evaluation Engine

Datengetriebene Selbstoptimierung: Universeller OCR-
Belegerkennungsprozess mit Fuzzy-Logik-basierter
Verfahrensauswahl

S

SMART

Heuristische Entscheidungen
aus Erfahrungswerten

C

COST-OPTIMIZED

Fortlaufende Minimierung der
Verarbeitungskosten

R

RECOGNITION

OCR-Erkennung und passende
Ressourceneinteilung

E

EVALUATION

Fortlaufende Score-
Berechnung und Vorprüfung

DOKUMENTENBASIS

Anforderungsdokument V 1.5

DATUM

14. Juli 2026

STATUS

Technisches Deck (12 Folien)

Das Grundproblem – Warum Selbstoptimierung?



Varianz der Belege

- ▮ **Heterogene Dokumente:** Rechnungen, Quittungen und Formulare unterscheiden sich massiv in Layout und Inhalt.
- ▮ **Bildqualität:** Schwankende Scanqualität, Rauschen, Skew oder Perspektiven verhindern eine "One-size-fits-all"-Lösung.
- ▮ **Starre Prozesse:** Fest verdrahtete OCR-Verfahren werden der Bandbreite der Praxisanforderungen nicht gerecht.



Kosten-Leistungs-Dilemma

- ▮ **Ressourceneffizienz:** Einfache Belege sind mit lokalen Modulen günstig lösbar, komplexe benötigen teure LLMs.
- ▮ **Fehlende Steuerung:** Bisher mangelt es an Mechanismen für eine automatische, kostenoptimale Verfahrenswahl pro Fall.
- ▮ **Daten-Nutzung:** Vorhandene Erfahrung aus abgeschlossenen Fällen wird bisher nicht systematisch für neue Entscheidungen genutzt.



Kernlösung: Datengetriebene Selbstoptimierung speichert Erfahrungen und speist diese automatisiert zurück in den Entscheidungsprozess ein.

Das Gesamtkonstrukt im Überblick

Der lernende Kreislauf der datengetriebenen Selbstoptimierung

1 Bildanalyse

Statische Analyse ohne OCR-Aufruf.

- Messgrößen-Vektor
- Bis zu 60 Merkmale

2 Distanzberechnung

Vergleich mit der SCORE-DB.

- Gewichtete Fuzzy-Suche
- Erfolgreiche Altfälle

3 Modul-Auswahl

Ermittlung des Vorschlags.

- Ähnlichster Nachbar
- Modul-Empfehlung

4 Ausführung

Technische Verarbeitung.

- Lokales OCR-Modul
- Leistungsstarkes LLM

5 Kostenerfassung

Ressourcenverbrauch prüfen.

- Token-Kumulierung
- Verarbeitungskosten

6 Bewertung

Plausibilitätsprüfung.

- Status-Überprüfung
- Optionale Eskalation

7 Rückmeldung

Externe Validierung.

- Manuelle Korrekturen
- DATEV-Synchronisation

8 Wissensbasis

Erfahrungsspeicherung.

- Update der SCORE-DB
- Lernende Grundlage

9 Housekeeping

Wöchentliche Optimierung.

- ML-Gewichtungsfaktoren
- Datenbereinigung



Kernprinzip: Jeder verarbeitete Fall wird unmittelbar Teil der zukünftigen Trainingsgrundlage und verbessert die heuristische Entscheidungsfindung.

Die vier Dimensionen der Selbstoptimierung

Ganzheitliche Systemverbesserung auf vier operativen Ebenen



DIMENSION 1

Gewichtungs-Optimierung

Optimiert die Relevanz einzelner Messgrößen für die Ähnlichkeitssuche. SCORE lernt kontinuierlich, welche Bildmerkmale den OCR-Erfolg tatsächlich vorhersagen.

 ML-Housekeeping (LightGBM)



DIMENSION 2

Kosten-Optimierung

Sicherstellung der Wirtschaftlichkeit durch dynamische Kostenfaktoren und Eskalations-Views. Automatische Anpassung an aktuelle Marktpreise der LLM-Anbieter.

 Dynamische Kostensteuerung




DIMENSION 3

Wissensbasis-Optimierung

Pflege der Vergleichsbasis durch einen lernenden Rückkopplungskreislauf. Intelligente Daten-Retention entfernt Redundanzen und erhält wertvolle Unikate.

 Feedback & Retention



DIMENSION 4

Struktur-Optimierung

Optimierung der Modul-Anbindung und Eskalations-Hierarchie. Schnelles Onboarding neuer Module durch Seeding ohne strukturelle Code-Änderungen.

 Dynamische Eskalation

Dimension 1 – Gewichtungs-Optimierung

ML-gestütztes Housekeeping zur automatischen Ermittlung relevanter Bildmerkmale.



Wöchentliches Housekeeping

- ▮ Vollständiges Einlesen der **SCORE-DB** für jedes Verarbeitungsmodul.
- ▮ Identifikation von Korrelationen zwischen Bildmerkmalen und OCR-Erfolg.
- ▮ Automatisches Update der Gewichtungsfaktoren w_i ohne Codeänderung.
- ▮ Kein manueller Eingriff oder Expertenwissen für Anpassungen nötig.



Technologie: LightGBM

- ▮ Einsatz von **Gradient Boosted Decision Trees** auf tabellarischen Daten.
- ▮ Effizienz: Training von 1 Mio. Datensätzen in Sekunden bis Minuten.
- ▮ Output: **Feature Importance** wird direkt als Gewichtung übernommen.

CLASSIC ML

TABULAR DATA

FAST TRAINING



Mathematische Wirkung

Die gelernten Faktoren optimieren die gewichtete euklidische Distanzberechnung:

$$\sum w_i \times (m_{\text{historisch},i} - m_{\text{aktuell},i})^2$$

- ▮ Stärkere Gewichtung von Merkmalen mit hoher Vorhersagekraft.
- ▮ Neutralisierung irrelevanter Rausch-Metriken (w_i gegen 0).



Selbstoptimierender Effekt

- ▮ Verbessert sich die Qualität eines Moduls (z.B. neues LLM), steigen dessen Erfolgstreffer in der DB.
- ▮ Das Housekeeping erkennt den Trend und erhöht die **Vorschlagswahrscheinlichkeit**.
- ▮ Das System adaptiert sich kontinuierlich an neue Modul-Leistungstufen.

Dimension 2 – Kosten-Optimierung

Minimierung der Verarbeitungskosten durch dynamische Steuerung und Eskalationslogik



Dynamische Kostenfaktoren (FA-16)

Zentraler Mechanismus zur Umrechnung von Token-Verbrauch in reale Kosten je Verfahren.

- Konfigurierbare Preismodelle für externe LLM-Dienste.
- Anpassung an laufende Marktveränderungen (Preis/Qualität).
- Lokale OCR wird stets mit **Kosten = 0** geführt (FA-15).



Kostenobergrenze & Fallback

Vorgabe einer strikten Obergrenze (max_kosten) durch den Auftraggeber zur Budgetkontrolle.

- Eskalationsstopp bei Erreichen des Kostenlimits.
- Automatischer Fallback auf das lokale OCR-Verfahren.



Flexible Eskalationslogik

Steuerung über den Parameter **strategie** zur Auswahl des nächsten Verarbeitungsmoduls:

Strategie: cost

Strategie: quality

- **Cost:** Eskalation nach aufsteigenden Durchschnittskosten.
- **Quality:** Fokus auf maximale Erkennungsrate.



Selbstoptimierender Effekt

Das Housekeeping integriert neue Preisinformationen automatisch in die SCORE-Datenbank.



Das System passt Kostenentscheidungen ohne manuellen Eingriff an die aktuelle Marktlage an.

Dimension 3 – Optimierung der Wissensbasis

Kontinuierliche Verbesserung der Datenbasis durch Rückkopplung manueller Korrekturen und intelligentes Housekeeping zur Bereinigung redundanter oder veralteter Datensätze bei Erhalt der Datenqualität.



Lernender Rückkopplungskreislauf

- ✓ Jeder abgeschlossene Verarbeitungsfall wird inklusive finalem Status unmittelbar Teil der SCORE-DB (FA-10).
- ✓ Nachträgliche Zuordnung verspäteter manueller Korrekturen (z. B. DATEV-Buchungen) zum Ursprungsdatensatz (FA-9).
- 🔗 Kontinuierliche Verbesserung künftiger Fuzzy-Treffer durch wachsende Vergleichshistorie.

Datenquelle: SCORE-DB & DATEV-Feedback



Housekeeping & Retention

- 🔗 Regelmäßige Prüfung der Datensätze auf Redundanz, Alter und Relevanz für die Ähnlichkeitssuche (FA-20).
- 🔗 Ausdünnung dichter Datenbereiche; Entfernung veralteter Modul- oder Preisversionen ohne Informationsverlust.
- 🔗 Sichere Batch-Löschung (10 Datensätze pro Durchlauf) zur Gewährleistung der Transaktionssicherheit.

Erhalt: Einzigartige & seltene Fälle

SELBSTOPTIMIERENDER EFFEKT

Die Wissensbasis bleibt gesund und performant — sie wächst gezielt um wertvolle neue Fälle und schrumpft automatisch um redundante oder obsolete Informationen.

Dimension 4 – Strukturelle Selbstoptimierung

Dynamische Eskalation und effizientes Onboarding neuer Module

Dynamische Eskalation

Die Eskalationshierarchie ist nicht fest kodiert, sondern wird über eine **Datenbank-View** dynamisch aus der SCORE-DB abgeleitet.

- ▮ Ermöglicht Anbindung beliebig vieler Module ohne Codeänderung.
- ▮ Flexible Reaktion auf neue Modul-Verfügbarkeiten.
- ▮ Automatische Anpassung der Rangfolge basierend auf Live-Daten.

Strategie-Steuerung

Die Sortierung der Eskalationsstufen folgt dem Parameter *strategie*:

COST

Aufsteigend nach durchschnittlichen Kosten.

QUALITY

Absteigend nach Erkennungsrate (letzte 100 Tage).


Effizientes Onboarding

Lösung des **Kaltstart-Problems** (FA-21) bei der Einführung neuer OCR- oder LLM-Verfahren ohne historische Daten.

- ▮ **Modul-Duplikation:** Datensätze eines vergleichbaren Bestandsmoduls dienen als Vorlage.
- ▮ **Kosten-Trigger:** Initialisierung mit Kosten = 0.
- ▮ **Bevorzugung:** Durch Null-Kosten wird das neue Modell in der Erprobungsphase priorisiert vorgeschlagen.

Seeding-Mechanismus

Systematischer Wissenstransfer für neue Komponenten:



Sobald echte Ergebnisse vorliegen, verdrängt die reale Performance die Seeding-Daten.

Das Herzstück: Der Messgrößen-Vektor

Wissenschaftlich fundierte Bildanalyse vor der eigentlichen OCR-Erkennung



Statische Bildanalyse

Rein heuristische Merkmalerfassung ohne teuren OCR-Vorabaufbau.



Vektor-Generierung

Erzeugung eines standardisierten Metrik-Sets (35 bis 60 Merkmale).

Normierung 0 bis 100

Alle Metriken werden auf eine einheitliche Skala normiert, um mathematische Vergleichbarkeit in der Fuzzy-Suche zu gewährleisten.

Min (0)

Max (100)

AUSZUG DER KERN-METRIKEN (ANHANG A)

- Bildschärfe & Kontrast
- Rauschen & Entropie
- Skew (Schiefelage)
- Perspektivverzerrung
- Mittlere Zeichenhöhe
- Helligkeitsverteilung
- Kantenintensität
- Layout-Komplexität

Wissenschaftliche Basis

Fundiert durch **DIQA** (Document Image Quality Assessment). Studien 2024–2025 belegen hohe Korrelation zum OCR-Erfolg.

Zukunftssicher

Erweiterbare Vektor-Struktur ermöglicht das Hinzufügen neuer Messgrößen ohne Schema-Änderung in der Datenbank.

Der Fuzzy-Mechanismus – Wie Erfahrung wirkt

Automatisierte Verfahrensauswahl durch gewichtete Ähnlichkeitsmetriken zu historischen Erfolgsfällen



1. Filterung

Nur Datensätze mit Status "erfolgreich" und ohne manuelle Nachbearbeitung werden berücksichtigt.



2. Berechnung

Ermittlung der gewichteten, quadrierten euklidischen Distanz zum aktuellen Messgrößen-Vektor.



3. Selektion

Wahl des ähnlichsten historischen Falls (Nearest Neighbor) aus der SCORE-Wissensbasis.



4. Übernahme

Das damals erfolgreiche Verarbeitungsmodul wird als verbindlicher Vorschlag übernommen.

$$d^2 = \sum w_i \times (m_{\text{hist},i} - m_{\text{akt},i})^2$$

Gewichtete quadratische euklidische Distanz

- **Modulspezifische Gewichte:** Faktoren w_i sind je Modul separat hinterlegt, da Merkmale unterschiedlich stark wirken.
- **Normierung:** Alle Messgrößen m sind auf einer Skala von 0 bis 100 standardisiert.
- **Empirie-Fokus:** Die Entscheidung basiert rein auf faktisch erfolgreichen historischen Instanzen.

TECHNOLOGISCHER AUSBLICK

Alternative Ähnlichkeitsmaße

Evaluierung von Manhattan-, Cosinus- und Tschebyschow-Distanzen für spezifische Belegtypen.

DuckDB VSS Extension


Integration der Vector Similarity Search für performante Abfragen in wachsenden Datenbeständen.

HNSW-Indexierung

Beschleunigte Suche über Hierarchical Navigable Small World Graphen für Sub-Sekunden-Antwortzeiten.

Monitoring-Dashboard – Selbstoptimierung sichtbar gemacht

Transparenz durch Visualisierung von Erkennungsraten, Modulqualität und Vorhersagekraft zur Systemüberwachung.



Zusammenfassung – Das selbstoptimierende Gesamtkonstrukt

Kontinuierliche Verbesserung durch datengetriebene Rückkopplung

DER GESCHLOSSENE OPTIMIERUNGSKREISLAUF

 Beleg & Statische Bildanalyse (Messgrößen-Vektor)



 Fuzzy-Ähnlichkeitssuche in der SCORE-Datenbank



 Modulwahl (Kosten- vs. Qualitätsoptimiert)



 Verarbeitung, Bewertung & Status-Erfassung



 Rückführung in Wissensbasis (Lerneffekt)

 *Wöchentliches ML-Housekeeping optimiert Gewichte, Kosten und Datenbestand automatisch.*

Gewichte (ML)

Lernen, welche Bildmerkmale wirklich für den OCR-Erfolg zählen.

Kosten

Anpassung an aktuelle Marktlage und Token-Preise der LLMs.

Wissensbasis

Pflege wertvoller Fälle und intelligente Daten-Retention.

Struktur

Dynamische Eskalation und nahtloses Onboarding neuer Module.

KERNAUSSAGE

SCORE ist kein statisches Regelwerk, sondern ein **datengetriebenes System**, das aus jedem Beleg lernt und dadurch fortlaufend präziser und kosteneffizienter wird — **vollständig ohne manuellen Eingriff**.